

### Agenda

- Seca
  - Impactos na qualidade da vegetação
  - Disseminação de esquistossomose
- Model Checking Probabilístico
- Modelo de predição de seca
  - NDVI time series and Markov Chains to model the change of fuzzy vegetative drought classes
- Estudo de Caso: disseminação de Esquistossomose
  - Utilização do modelo de mistura espectral do sensor MODIS no estudo da distribuição da esquistossomose e de *Biomphalaria glabrata* no Estado de Minas Gerais
- Modelagem
- Resultados
- Conclusões

### Introdução

23/03/2017 08h23 - Atualizado em 23/03/2017 10h02

### Seca no RN causa R\$ 4 bi de prejuízo; 153 cidades têm emergência renovada

Publicado nesta quinta-feira (23), novo decreto tem validade de 180 dias. Documento leva em consideração os últimos 5 anos de estiagem severa.

29/06/2012 11h28 - Atualizado em 29/06/2012 15h36

# Seca faz mais da metade das cidades de SC decretar emergência

Ao menos 152 municípios pediram ajuda para combater efeitos da estiagem. Estado realiza audiências para decidir destino de subsídio a agricultores.

Edição do dia 19/09/2016

19/09/2016 08h02 - Atualizado em 19/09/2016 12h15

## Seca no Centro-Oeste deixa reservatórios em nível crítico

Para manter o abastecimento, alguns estados estão fazendo racionamento. Se não chover nos próximos dias, o risco de racionamento geral é grande.





### Introdução

- Secas → estresse vegetativo
- Resposta ao deficit hídrico
  - Diminuição da área foliar
  - Acentuado crescimento das raízes

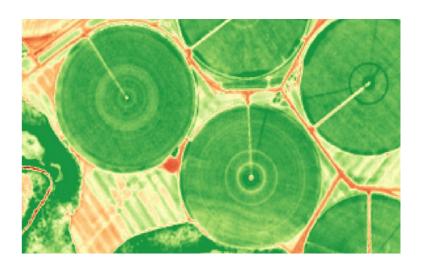




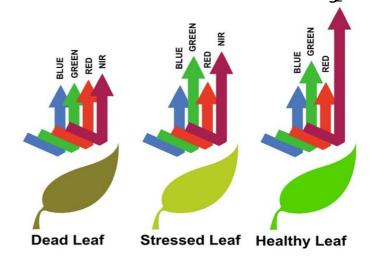
### Introdução

 Imagens de satélite podem auxiliar na identificação de anomalias em plantações, solo, corpos d'água e florestas

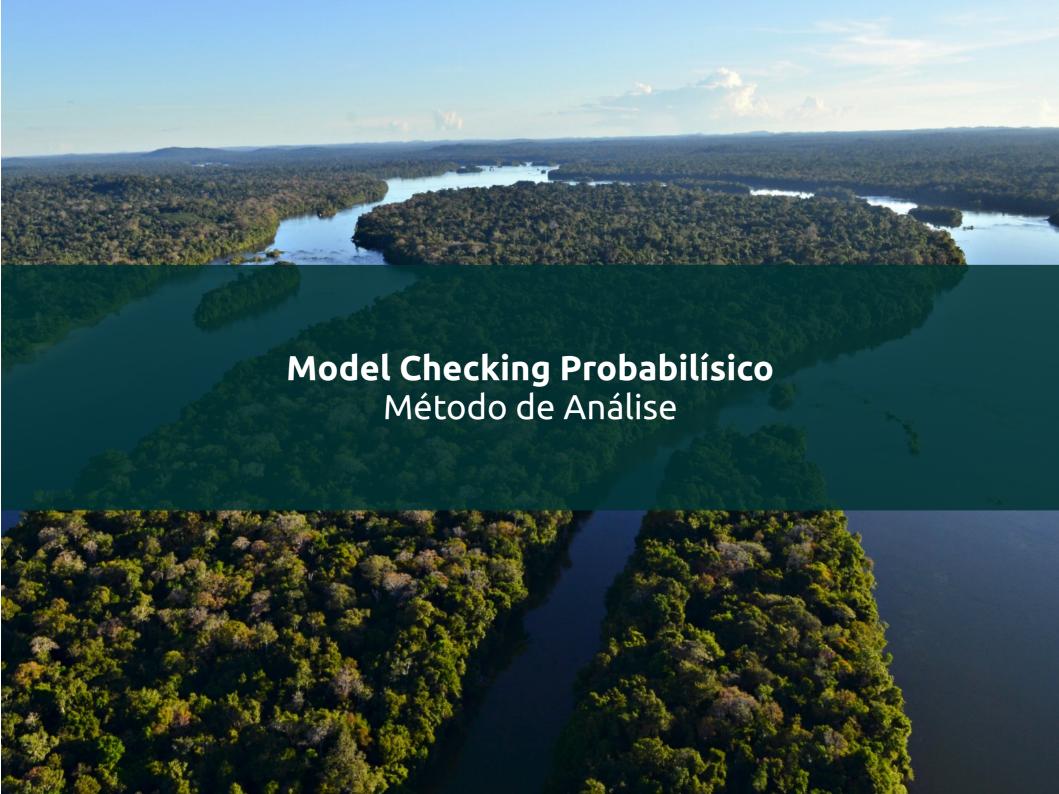
- Normalized Difference Vegetation Index (NDVI)
- Auxílio na identificação de anomalias de vegetação



Anomalia por falhas no sistema de irrigação Consequência: comprometimento do rendimento da lavoura em determinadas regiões







### Model Checking Probabilístico (MCP)

 Análise matemática de provar ou não provar a corretude de um sistema de hardware ou software com relação a uma certa especificação ou propriedade [Ganai and Gupta 2007]

- Máquinas de estados finitos → modelo
- Lógica formal → propriedades

### Introdução – PRIS Model Checker

- Construção de modelos determinísticos para análise de propriedades especificadas por meio de lógica temporal
- Estimação de probabilidades e custos
- Linguagem de especificação própria
  - módulos
  - variáveis
- Tipos de modelos
  - DTMC → Cadeia de Markov de Tempo Discreto
  - CTMC → Cadeia de Markov de Tempo Contínuo
  - MDP → Processos de Decisão Markoviano
  - PTA → Autômatas Temporizados Probabilísticos

### Introdução – PRIS Model Checker

- Construção de modelos determinísticos para análise de propriedades especificadas por meio de lógica temporal
- Linguagem de especificação própria
  - módulos
  - variáveis
- Tipos de modelos
  - DTMC → Cadeia de Markov de Tempo Discreto
  - CTMC → Cadeia de Markov de Tempo Contínuo
  - MDP → Processos de Decisão Markoviano
  - **PTA** → Autômatas Temporizados Probabilísticos

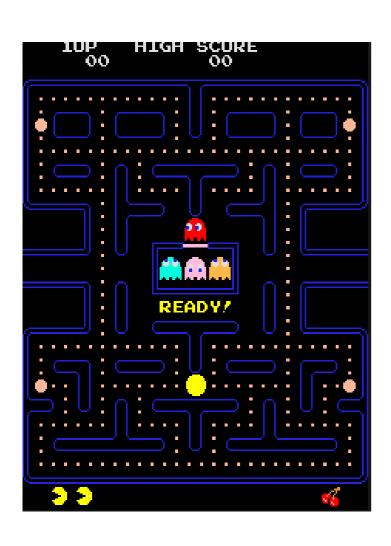
### Prism Model Checker

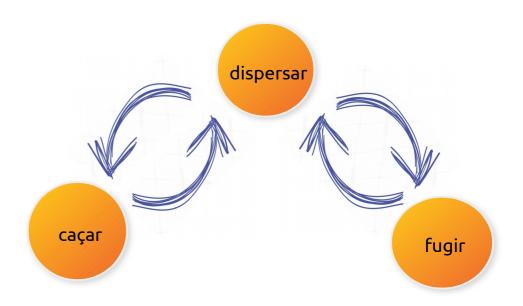
• Comportamento dos módulos é especificado por comandos

```
[ ] guarda - > probabilidade : atualização + . . . + probabilidade_n : atualização_n;
```

- guarda → condição necessária para realizar uma transição de um estado a outro
- probabilidade → probabilidade da transição ocorrer
- Atualização → atualização dos valores das variáveis

### MCP - Exemplo





### Exemplos de especificações..

- . tempo\_dispersar >= 5
- . tempo\_caçar >= 20
- . tempo\_player\_energia >= 10



### NDVI TIME SERIES AND MARKOV CHAINS TO MODEL THE CHANGE OF FUZZY VEGETATIVE DROUGHT CLASSES

S. Ding, C. M. Rulinda, A. Stein, W. Bijker

University of Twente

Department of Earth Observation Science, Faculty of Geo-information Science and Earth Observation Hengelosestraat 99, 7500 AE, Enschede, The Netherland

#### ABSTRACT

The objective of this study is to explore the potential of using Markov chains to model the changes of vegetative drought classes. NOAA-AVHRR dekadal NDVI images and fuzzy functions are used to characterize the drought classes while capturing the gradual transition between them. The transition probabilities are estimated using the maximum class membership values at a location. The Markov transition probability matrix is then used to model the changes of vegetative drought classes at selected locations. Future vegetative drought classes are predicted using the estimated transition matrix, then compared with actual data. Twenty pixel loca-

In this study [5] we combine Markov Chains with fuzzy sets theory to predict the future states of vegetative drought. The method is applied on 20 pixel-locations clustered in four different study areas within Kenya [5]: Region 1, centered at **P1** (3.117N, 35.617E); Region 2, centered at **P2** (1.75N, 40.067E); Region 3, centered at **P3** (0.5S, 37.45E), and Region 4, centered at **P1** (3.4S, 38.567E) respectively, as shown in **Fig.1**. The agriculture type of Regions 1 and 2 is pastoral farming, while in Regions 3 and 4 it is cultivation. NDVI data from the years 2004 to 2008, as well as the long term mean calculated from 1982 to 2005 are used.

- Contribuições de interesse:
  - exploração do potencial do uso de Cadeias de Markov para modelar as mudanças causadas por estresse vegetativo devido a seca
  - Identificação de 6 classes de estresse vegetativo → fuzzy
  - Uso de cadeias de Markov para modelar as mudanças devido ao estresse vegetativo ocasionado pela seca

- Definição da matriz de transição de probabilidades
  - Dados de NDVI de 2004 a 2008 → curto prazo
  - Dados de NDVI de 1982 a 2005 → longo prazo

$$\mathbf{P} = \begin{bmatrix} \mathbf{0.596} & 0.211 & 0.059 & 0.027 & 0.033 & 0.074 \\ 0.190 & \mathbf{0.434} & 0.175 & 0.066 & 0.020 & 0.115 \\ 0.108 & 0.194 & \mathbf{0.324} & 0.144 & 0.072 & 0.158 \\ 0.021 & 0.067 & 0.163 & \mathbf{0.351} & 0.247 & 0.151 \\ 0.016 & 0.025 & 0.061 & 0.141 & \mathbf{0.531} & 0.227 \\ 0.018 & 0.036 & 0.032 & 0.021 & 0.099 & \mathbf{0.793} \end{bmatrix}$$

Matriz de transição de probabilidades

 Matriz de transição de probabilidades é estimada de acordo com a equação:

$$\mathbf{P} = [p_{ij}] = P(X_t = j | X_{t-1} = i)$$

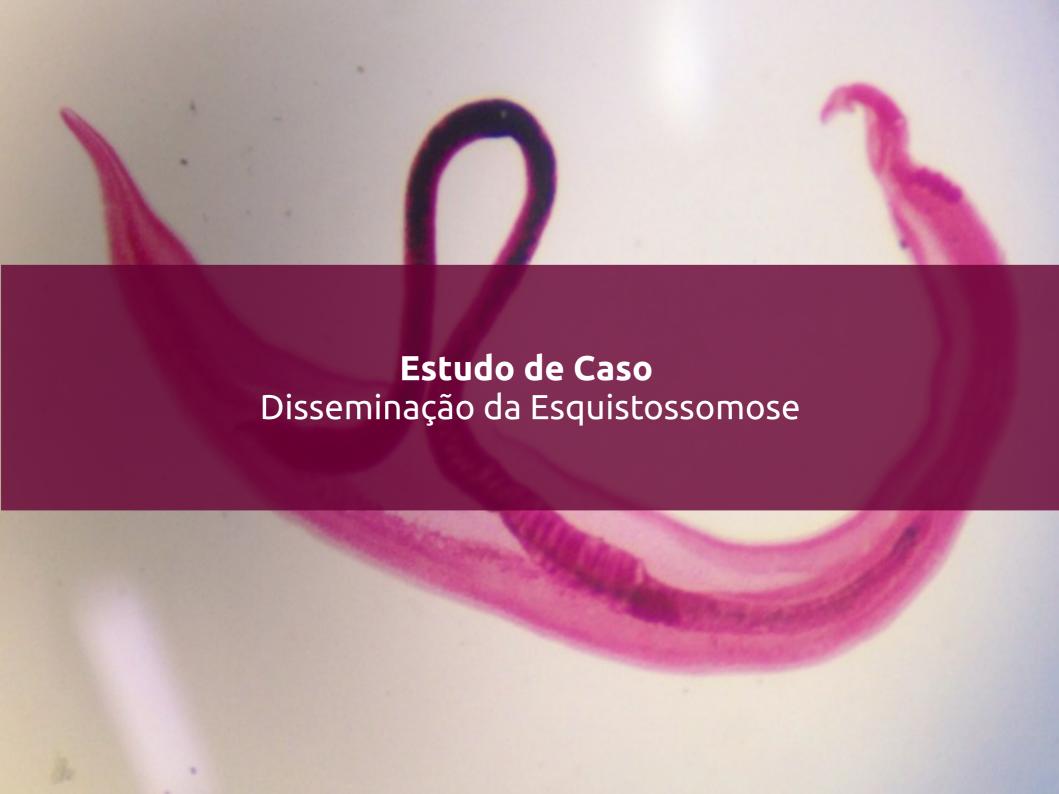
- Onde:

$$p_{ij}=rac{n_{ij}}{\sum n_{ij}}\geq 0, \sum n_{ij}=1$$
  $ightarrow$  é definido como um elemento da matriz de probabilidades P

Predição é estimadas de acordo com a equação:

$$\mu(x)_{t+1} = f(x)_t * \mathbf{P}$$

 $-x \rightarrow \text{\'e}$  o valor do pixel para as classes no tempo t + 1



### Utilização do modelo de mistura espectral do sensor MODIS no estudo da distribuição da esquistossomose e de *Biomphalaria glabrata* no Estado de Minas Gerais

Ricardo José de Paula Souza e Guimarães<sup>1,2</sup>
Corina da Costa Freitas<sup>1</sup>
Luciano Vieira Dutra<sup>1</sup>
Yosio Edemir Shimabukuro<sup>1</sup>
Fernanda Rodrigues Fonseca<sup>1</sup>
Flavia de Toledo Martins<sup>1</sup>
Ana Clara Mourão Moura<sup>3</sup>
Ronaldo Santos do Amaral<sup>4</sup>
Sandra Costa Drummond<sup>5</sup>
Ronaldo Guilherme Carvalho Scholte<sup>2,6</sup>
Omar dos Santos Carvalho<sup>6</sup>

**Abstract**. This work compares the prevalence of schistosomiasis and presence of *Biomphalaria glabrata* from the State of Minas Gerais with the vegetation, soil and shade fraction images, obtained through the application of the linear spectral mixture model in the MODIS data acquired in January and July 2002. The results showed that there is a positive correlation between prevalence and vegetation fraction image (July 2002), a negative correlation between prevalence and soil fraction image (July 2002), and a positive correlation between *B. glabrata* and shade fraction image (July 2002).

**Palavras-chave:** remote sensing, image processing, linear spectral mixture model, schistosomiasis, sensoriamento remoto, processamento de imagens, modelo de mistura, esquistossomose.

### Abundância e infecção do molusco Biomphalaria glabrata pelo Schistosoma mansoni no Estado do Rio de Janeiro, Brasil

Abundance and Schistosoma mansoni infection of the snail Biomphalaria glabrata, Brazil

Alexandre Giovanelli<sup>a</sup>, Marisa S Soares<sup>a</sup>, Paulo S D'Andréa<sup>b</sup>, Margareth Maria Lessa Gonçalves<sup>a</sup> e Luís Rey<sup>b</sup>

<sup>a</sup>Departamento de Biologia do Instituto Oswaldo Cruz (Fiocruz). Rio de Janeiro, RJ, Brasil.
<sup>b</sup>Departamento de Medicina Tropical da Fiocruz. Rio de Janeiro, RJ, Brasil

#### Descritores

Schistosoma mansoni.\* Biomphalaria, parasitologia.\* Ecologia de vetores.\* Relações hospedeiro-parasita. Distribuição espacial. Esquistossomose mansoni, transmissão. — Biomphalaria glabrata.

#### Resumo

#### Objetivos

Investigar a distribuição espacial, a abundância e os índices de infecção natural de Biomphalaria glabrata, hospedeiro intermediário do Schistosoma mansoni, em localidade do Estado do Rio de Janeiro, RJ, Brasil.

#### Métodos

Na localidade de Pamparrão, município de Sumidouro, RJ, as coletas de moluscos foram realizadas bimestralmente no período de junho de 1991 a novembro de 1995. Foram estabelecidos 23 pontos de coleta ao longo do córrego Pamparrão e três de seus afluentes. Os moluscos capturados foram levados ao laboratório para diagnóstico da infecção. Para a análise dos dados, foram usados o coeficiente de *Spearman* (nível de 0,5% de significância) e o teste de qui-quadrado.

#### Resultados

A abundância populacional de B. glabrata foi bastante variável ao longo do tempo e entre os ambientes amostrados. A maioria dos pontos de coleta apresentou correlação negativa com a pluviosidade. O afluente B destacou-se dos demais corpos d'água por apresentar taxas de infecção de B. glabrata elevadas (acima dos 25% em alguns pontos de coleta) e persistentes. Foram encontrados mais moluscos infectados na estação seca do que na chuvosa ( $\chi^2$ =20,08; p=0,001).

 Doença ocasionada pelo verme Schistosoma mansoni

- Ataca o fígado
- Hospedeiro intermediário → Biomphalaria glabrata
  - Reprodução e expansão da doença relacionada fatores ambientais



Schistosoma mansoni

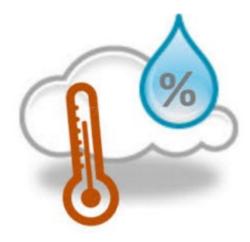


Biomphalaria glabrata

- Contribuições de interesse
  - Análise da correlação entre a expansão da esquistossomose e os fatores ambientais sombra, solo e vegetação em época de seca
  - Estudo de caso → Região de Minas Gerais









### Objetivo

- Definição do Modelo Probabilístico
  - Cadeia de Markov que descreve 6 estágios de seca
  - Influência da precipitação na evolução da seca
  - Influência da precipitação e da seca na reprodução do hospedeiro intermediário da esquistossomose
- Região de Estudo
  - Minas Gerais

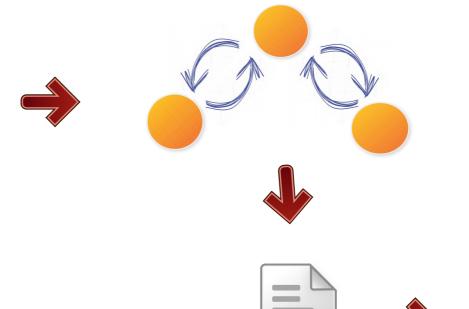
### Objetivo

- Com base no modelo probabilístico → definição de custos e propriedades
  - Identificação de anomalias de vegetação;
  - Identificação de períodos de maior reprodução dos caramujos em relação a seca e a precipitação;
  - Perda de densidade de vegetação ao longo do tempo;
  - Identificar a influencia das classes de seca em cada uma das variáveis;
  - Etc...

## Objetivo

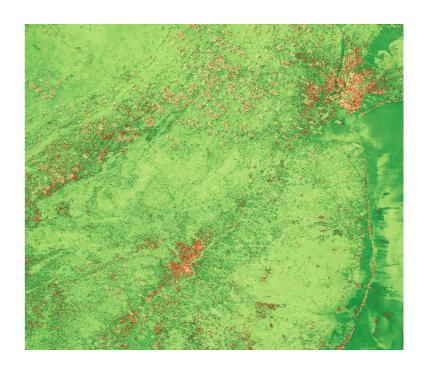






### Dados para validação

- Banda NDVI sensor MODIS
   → caatinga/cerrado
   brasileiro
- 17/01/2002 a 28/07/2002
- Seleção de uma região com 9 pixels
- Dados relacionados a expansão da esquistossomose foram retirados de [Guimarães et. al 2007]

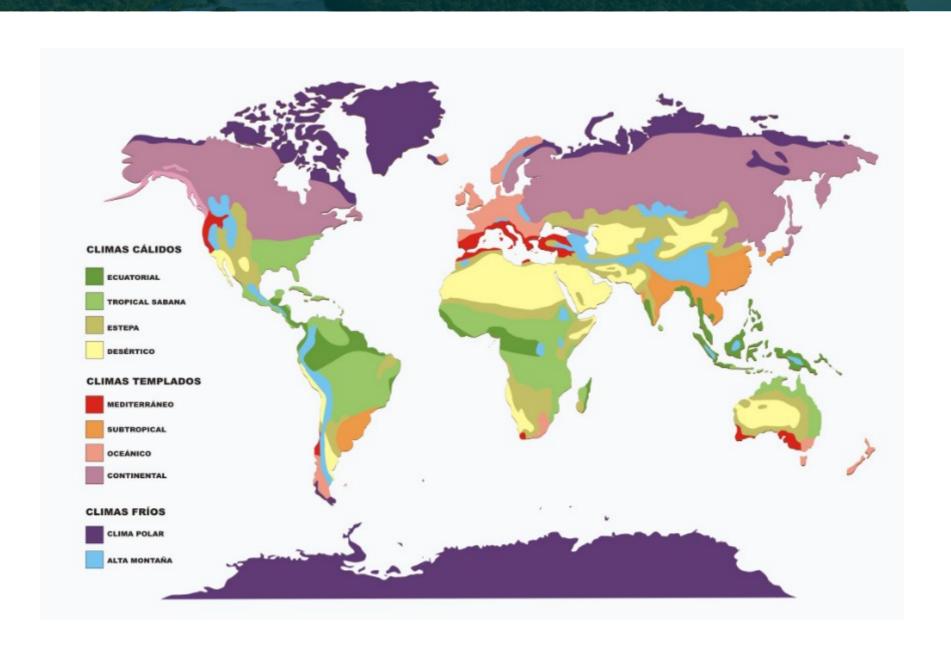


## Adaptação do modelo Variáveis inseridas

- Precipitação
  - Definição de três classes
    - Pouca
    - Média
    - Muita
- As probabilidades de transição das classes de seca foram alteradas de acordo com a precipitação. Exemplo:

$$\mathbf{P} = \begin{bmatrix} \mathbf{0.596} & 0.211 & 0.059 & 0.027 & 0.033 & 0.074 \\ 0.190 & \mathbf{0.434} & 0.175 & 0.066 & 0.020 & 0.115 \\ 0.108 & 0.194 & \mathbf{0.324} & 0.144 & 0.072 & 0.158 \\ 0.021 & 0.067 & 0.163 & \mathbf{0.351} & 0.247 & 0.151 \\ 0.016 & 0.025 & 0.061 & 0.141 & \mathbf{0.531} & 0.227 \\ 0.018 & 0.036 & 0.032 & 0.021 & 0.099 & \mathbf{0.793} \end{bmatrix}$$

### Aplicabilidade → Kenya x Minas Gerais



### Modelo de Predição de Seca (Relembrando)

 Matriz de transição de probabilidades é estimada de acordo com a equação:

$$\mathbf{P} = [p_{ij}] = P(X_t = j | X_{t-1} = i)$$

Onde:

$$p_{ij}=rac{n_{ij}}{\sum n_{ij}}\geq 0, \sum n_{ij}=1$$
  $ightarrow$  é definido como um elemento da matriz de probabilidades P

Predição é estimadas de acordo com a equação:

$$\mu(x)_{t+1} = f(x)_t * \mathbf{P}$$

 $-x \rightarrow \text{\'e}$  o valor do pixel para as classes no tempo t + 1

# Adaptação do modelo Variáveis inseridas

```
dtmc
const int precipitacao acumulada;
const int umidade;
const int temperatura;
module influencia preciptacao
                                  // estados
                                crescimento caramujos : [0..1] init 0;
                                  estado classe atual rl : [0..5] init 0;
                                  estado classe anterior rl : [0..5] init 0;
                                  densidade rl : [0..10] init 1;
                                  [] estado classe atual rl=0 & precipitacao acumulada <= 0.33 -> 0.059 : (estado classe atual rl'=0) & (estado classe anterior rl'=estado
                                  [] estado classe atual rl=0 & precipitacao acumulada >= 0.33 -> 0.211 : (estado classe atual rl'=0) & (estado classe anterior rl'=estado
                                  [] estado classe atual rl=0 & precipitacao acumulada <= 0.66 & precipitacao acumulada >= 0.33 -> 0.596 : (estado classe atual rl'=0) & (@estado classe atua
                                  [] estado classe atual r1=0 & precipitacao acumulada >= 0.66 -> 0.596 : (estado classe atual r1'=0) & (estado classe anterior r1'=estado
                                  [] estado classe atual r1=0 & precipitação acumulada <= 1 & precipitação acumulada >= 0.66 -> 0.074 : (estado classe atual r1'=0) & (esta
                                  [] estado classe atual rl=1 & precipitacao acumulada <= 0.33 -> 0.190 : (estado classe atual rl'=0) & (estado classe anterior rl'=estado
                                  [] estado classe atual rl=1 & precipitação acumulada >= 0.33 -> 0.190 : (estado classe atual rl'=0) & (estado classe anterior rl'=estado
                                  [] estado classe atual rl=1 & precipitacao acumulada <= 0.66 & precipitacao acumulada >= 0.33 -> 0.190 : (estado classe atual rl'=0) & (@estado classe atua
                                  [] estado classe atual rl=1 & precipitacao acumulada >= 0.66 -> 0.190 : (estado classe atual rl'=0) & (estado classe anterior rl'=estado
                                  [] estado classe atual rl=1 & precipitacao acumulada <= 1 & precipitacao acumulada >= 0.66 -> 0.190 : (estado classe atual rl'=0) & (estado classe atual rl'
                                  [] estado classe atual rl=2 & precipitacao acumulada <= 0.33 -> 0.108 : (estado classe atual rl'=0) & (estado classe anterior rl'=estado
                                  [] estado classe atual rl=2 & precipitacao acumulada >= 0.33 -> 0.108 : (estado classe atual rl'=0) & (estado classe anterior rl'=estado
                                  [] estado classe atual rl=2 & precipitacao acumulada <= 0.66 & precipitacao acumulada >= 0.33 -> 0.108 : (estado classe atual rl'=0) & (@estado classe atua
                                  [] estado classe atual rl=2 & precipitacao acumulada >= 0.66 -> 0.108 : (estado classe atual rl'=0) & (estado classe anterior rl'=estado
                                  [] estado classe atual rl=2 & estado classe atual rl=1 & precipitacao acumulada <= 1 & precipitacao acumulada >= 0.66 -> 0.108 : (estado
                                  [] estado classe atual rl=3 & precipitacao acumulada <= 0.33 -> 0.021 : (estado classe atual rl'=0) & (estado classe anterior rl'=estado
                                  [] estado classe atual rl=3 & precipitacao acumulada >= 0.33 -> 0.021 : (estado classe atual rl'=0) & (estado classe anterior rl'=estado
                                  [] estado classe atual rl=3 & precipitacao acumulada <= 0.66 & precipitacao acumulada >= 0.33 -> 0.021 : (estado classe atual rl'=0) & (@atual rl'=0) | (estado classe atual rl'=0) | (est
                                  [] estado classe atual rl=3 & precipitacao acumulada >= 0.66 -> 0.021 : (estado classe atual rl'=0) & (estado classe anterior rl'=estado
                                  [] estado classe atual rl=3 & estado classe atual rl=1 & precipitacao acumulada <= 1 & precipitacao acumulada >= 0.66 -> 0.021 : (estado
```

# Adaptação do modelo Variável inseridas

- Quantidade de Caramujos
  - Variável que guarda a quantidade de caramujos gerados em cada classe

# Adaptação do modelo Variável de controle

- Determinação da perda/ganho de densidade de vegetação
  - Variável que guarda o estado antigo
    - Avanço de classes → perda
    - Regressão de classes → ganho

```
rewards "densidade_vegetacao"
//true: 0.0;
    estado_classe_atual_rl < estado_classe_anterior_rl : 0.5*densidade_rl;
    estado_classe_atual_rl > estado_classe_anterior_rl : 1*densidade_rl;
endrewards

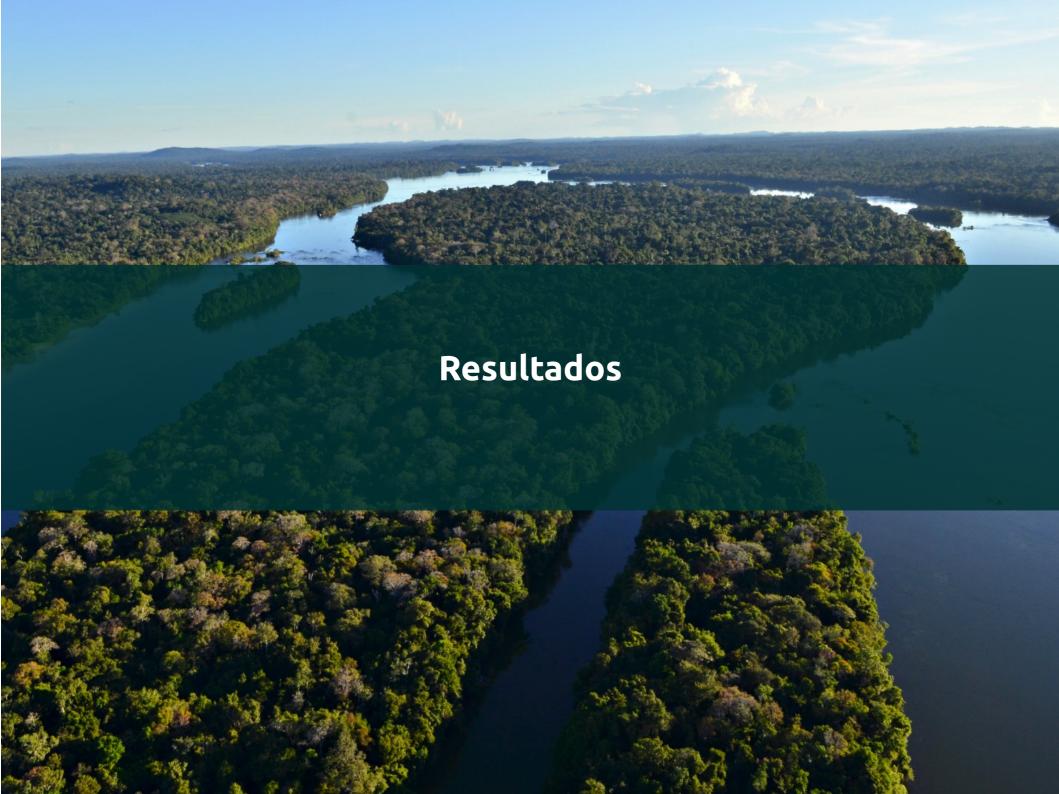
2
```

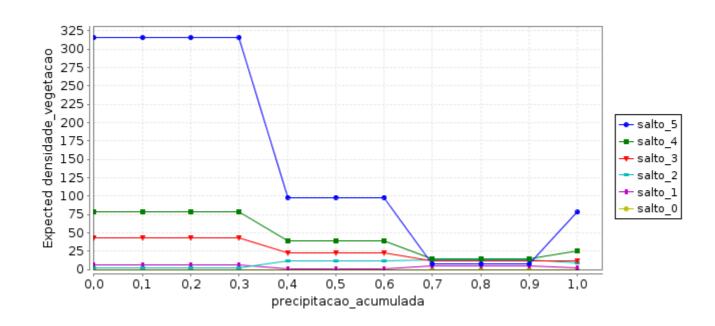
# Adaptação do modelo Variável de controle

- Determinação da perda/ganho de densidade de vegetação
  - Variável que guarda o estado antigo
    - Avanço de classes → perda
    - Regressão de classes → ganho

```
rewards "densidade_vegetacao"
//true: 0.0;
    estado_classe_atual_rl < estado_classe_anterior_rl : 0.5*densidade_rl;
    estado_classe_atual_rl > estado_classe_anterior_rl : 1*densidade_rl;
endrewards

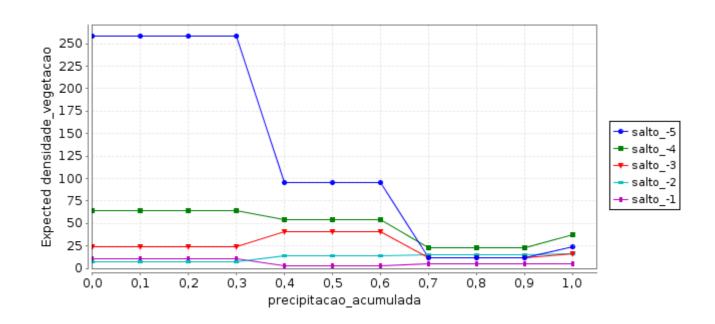
2
```





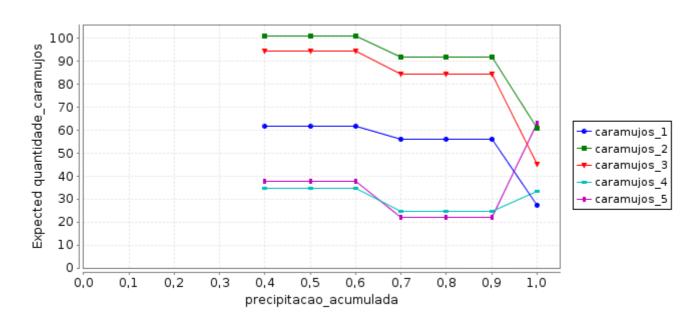
### Propriedade:

- R{"densidade\_vegetacao"}= ? [ F estado\_classe\_atual\_r2 estado\_classe\_anterior\_r2 = n ], com 0<= n <=5
- Interpretação:
  - Decrescimento linear da densidade de vegetação a medida em que os saltos de estágios melhores de seca pulam para estágios piores de seca. Observe que a precipitação influência positivamente no crescimento da densidade vegetativa, pois conforme o aumento da precipitação, há uma diminuição na intensidade de decrescimento da densidade vegetativa, até que, a partir de 0.9 de precipitação, o quadro de decrescimento é revertido.



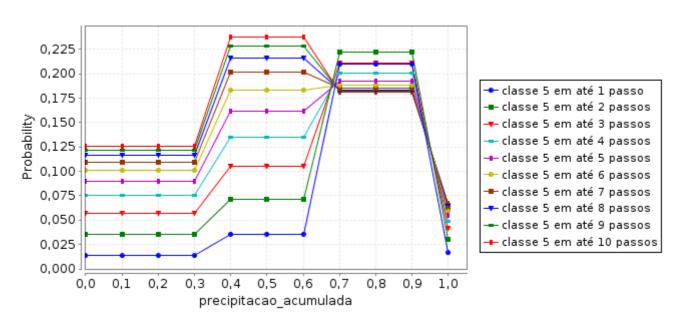
### Propriedade:

- R{"densidade\_vegetacao"}=?[Festado\_classe\_atual\_r2 estado\_classe\_anterior\_r2 = n],
   com -5<= n <=0</li>
- Interpretação:
  - Influência da precipitação é mais forte em situações em que há uma transição "natural" (pulos pequenos) de um estágio a outro.

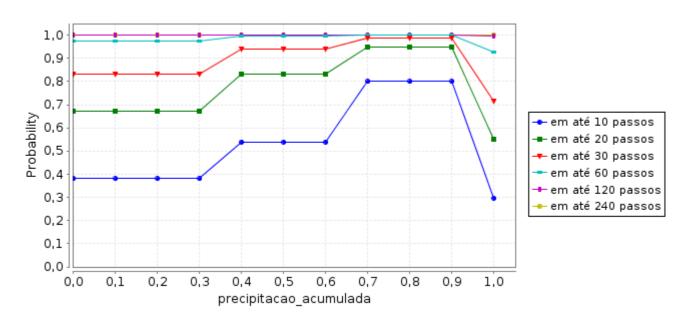


### Propriedade:

- R{"quantidade\_caramujos"}=? [ F estado\_classe\_anterior\_r2=  $n \& precipitacao_acumulada>=0.33$  ], com 0 <= n <=5
- Interpretação:
  - A medida em que se está em estágios de seca severa (estágios menores) há pouca influência da precipitação. A medida em que há melhora em relação a seca, a influência da precipitação no crescimento de caramujos passa a ser mais forte.



- Propriedade:
  - P=? [F = n estado\_classe\_atual\_r1=5], com 1<= n <=10
- Interpretação:
  - Probabilidade de ocorrer o estado de seca mais brando no instante de tempo n
  - Observe que a probabilidade é diretamente proporcional a quantidade de passos avançam



- Propriedade:
  - P=? [estado\_classe\_atual\_r1 < 5 U<= n estado\_classe\_atual\_r1=5 ], com 1<= n <=10
- Interpretação:
  - Probabilidade de chegar no estágio de seca mais brando, partindo de estágios obrigatoriamente mais secos em até n passos de tempo

- Propriedade:
  - P>=1 [G F ( estado\_classe\_atual\_r1=4 & (X estado\_classe\_atual\_r1=5)) ]
- Interpretação:
  - Infinitamente e frequentemente acontecerá o estado 4 e o próximo obrigatoriamente será o estágio 5

- Propriedade:
  - P =? [(F estado\_classe\_atual\_r1=0) & (F estado\_classe\_atual\_r1=5)]
- Interpretação:
  - Frequentemente passará pelos estados extremos de seca

